Analisis Sentimen Pengguna Aplikasi Roblox Berdasarkan Ulasan Menggunakan Metode Machine Learning

Pandu Setiawan [1,*], Alvin Zhakaria [2], Farhan Fadillah Mandey [3], Ika Kurniawati [4], Waeisul Bismi [5], Riza Fahlapi [6]

Teknik Informatika, Universitas Bina Sarana Informatika, Jl. Kramat Raya No.98, RT.2/RW.9, Kwitang, Kec. Senen, Kota Jakarta Pusat, Daerah Khusus Ibukota Jakarta, 10450
[1]pandu.setiawan1163@gmail.com; [2]rosaalvin84@gmail.com; [3]mandeyfarhan@gmail.com; [4]ika.iki@bsi.ac.id; [5]waeisul.wbn@bsi.ac.id; [6]riza.rzf@bsi.ac.id

* Penulis Korespondensi

ABSTRAK

Ulasan pengguna di Google Play Store dapat digunakan untuk memahami kepuasan dan keluhan melalui analisis sentimen. Penelitian ini mengklasifikasikan sentimen ulasan aplikasi Roblox berbahasa Indonesia dan membandingkan performa beberapa model machine learning. Data diambil dengan scraping 20.000 ulasan dari com.roblox.client, lalu diproses melalui pembersihan teks, case folding, normalisasi kata, tokenisasi, stopwords removal, dan stemming Sastrawi. Sentimen dilabeli otomatis berdasarkan skor, yaitu negatif untuk skor ≤ 3 dan positif untuk skor > 3. Fitur diekstraksi menggunakan TF-IDF dan diuji pada model SVM linear, Multinomial Naive Bayes, dan MLP, serta dilakukan eksperimen SMOTE untuk menangani ketidakseimbangan kelas. Evaluasi menggunakan akurasi dan AUC-ROC. Hasil terbaik diperoleh SVM tanpa SMOTE dengan akurasi 82,51% dan AUC 87,41%. SMOTE menurunkan performa SVM, tetapi meningkatkan Naive Bayes, sementara MLP menunjukkan performa lebih rendah. Secara umum, SVM paling konsisten, dan SMOTE lebih bermanfaat pada Naive Bayes

KATA KUNCI
Analisis sentiment
Roblox
Naïve Bayes
Support Vector Machine
MLP.

ABSTRACT

User reviews on the Google Play Store can be used to understand user satisfaction and complaints through sentiment analysis. This study classifies the sentiment of Indonesian-language Roblox app reviews and compares the performance of several machine learning models. The data were collected by scraping 20,000 reviews from com.roblox.client, then processed through text cleaning, case folding, word normalization, tokenization, stopword removal, and Sastrawi stemming. Sentiment labels were automatically assigned based on review scores: negative for scores ≤ 3 and positive for scores > 3. Features were extracted using TF-IDF and evaluated with linear SVM, Multinomial Naive Bayes, and MLP, with an additional SMOTE experiment to address class imbalance. Evaluation used accuracy and AUC-ROC. The best results were achieved by SVM without SMOTE, with an accuracy of 82.51% and an AUC of 87.41%. SMOTE reduced SVM performance but improved Naive Bayes, while MLP showed lower performance. Overall, SVM was the most consistent model, and SMOTE was more beneficial for Naive Bayes.

KEYWORD
Sentiment Analysis
Roblox
Naïve Bayes
Support Vector Machine
MLP.

This is an open-access article under the CC–BY-SA license

1. Pendahuluan

Perkembangan aplikasi berbasis mobile mendorong meningkatnya interaksi pengguna melalui fitur ulasan pada Google Play Store. Ulasan tersebut memuat opini, keluhan, serta apresiasi pengguna terhadap kualitas aplikasi, seperti stabilitas sistem, kenyamanan penggunaan, dan pengalaman bermain. Jumlah ulasan yang terus bertambah membuat analisis manual menjadi tidak efisien, sehingga diperlukan metode otomatis untuk mengekstraksi informasi penting dari teks ulasan.

Analisis sentimen merupakan salah satu pendekatan dalam text mining yang bertujuan mengidentifikasi kecenderungan opini pengguna, umumnya dalam bentuk kategori positif dan negatif. Penerapan analisis sentimen pada ulasan aplikasi dapat membantu pengembang memahami persepsi pengguna secara lebih cepat dan terukur, sekaligus menjadi dasar untuk menentukan prioritas perbaikan atau pengembangan fitur. Dalam konteks aplikasi Roblox yang memiliki basis pengguna luas, ulasan

pengguna cenderung beragam dan dinamis, sehingga menarik untuk dianalisis menggunakan pendekatan machine learning.

Penelitian-penelitian sebelumnya telah banyak menerapkan machine learning untuk klasifikasi sentimen ulasan aplikasi. Namun, berdasarkan telaah awal yang kami lakukan, sebagian penelitian masih menggunakan jumlah data relatif terbatas, umumnya sekitar 10.000 ulasan atau kurang, serta hanya membandingkan dua algoritma klasifikasi. Keterbatasan tersebut berpotensi membuat hasil kurang merepresentasikan variasi opini pengguna secara lebih luas, serta membatasi pemahaman mengenai kinerja algoritma lain yang mungkin lebih sesuai untuk data tertentu.

Berbeda dari penelitian sebelumnya, penelitian ini menggunakan dataset yang lebih besar, yaitu 20.000 ulasan aplikasi Roblox berbahasa Indonesia yang dikumpulkan melalui proses scraping dari Google Play Store. Selain itu, penelitian ini membandingkan tiga algoritma, yaitu Support Vector Machine (SVM), Multinomial Naive Bayes, dan pendekatan deep learning sederhana menggunakan Multi-Layer Perceptron (MLP). Dengan jumlah data yang lebih besar dan variasi algoritma yang lebih beragam, penelitian ini diharapkan memberikan gambaran performa model yang lebih komprehensif untuk klasifikasi sentimen ulasan aplikasi, serta membantu menentukan algoritma yang paling sesuai untuk karakteristik data ulasan Roblox.

2. Tinjauan Pustaka

2.1 Analisis Sentimen

Analisis sentimen mengklasifikasikan opini dalam teks menjadi kategori tertentu (misalnya positif/negatif). Dalam konteks ulasan aplikasi, analisis sentimen bermanfaat untuk menangkap persepsi pengguna secara ringkas dan terukur.

2.2 Pra-pemrosesan Teks Bahasa Indonesia

Pra-pemrosesan bertujuan mengurangi noise dan menormalkan kata agar model lebih mudah belajar. Tahapan umum meliputi pembersihan karakter non-teks, case folding, tokenisasi, penghapusan stopwords, serta stemming. Untuk bahasa Indonesia, stemming dapat dilakukan dengan pustaka Sastrawi/PySastrawi untuk mengubah kata berimbuhan menjadi bentuk dasar. Penggunaan stopwords pada NLTK sering dijadikan acuan dalam pemrosesan bahasa alami.

2.3 Representasi Fitur: Bag-of-Words dan TF-IDF

Bag-of-Words merepresentasikan dokumen sebagai frekuensi kemunculan kata. TF-IDF menyempurnakan bobot dengan mempertimbangkan kelangkaan kata pada korpus, sehingga kata yang terlalu umum cenderung berbobot lebih kecil. Konsep pembobotan TF-IDF banyak digunakan dalam information retrieval dan klasifikasi teks. Implementasi TF-IDF dapat dilakukan menggunakan TfidfVectorizer pada scikit-learn.

2.4 Support Vector Machine

SVM adalah metode klasifikasi yang mencari hyperplane terbaik untuk memisahkan kelas. SVM efektif untuk data berdimensi tinggi seperti data teks, terutama dengan kernel linear.

2.5 Multinomial Naive Bayes

Naive Bayes memanfaatkan probabilitas bersyarat antar fitur dengan asumsi independensi. Pada klasifikasi teks, Multinomial Naive Bayes umum digunakan karena sesuai dengan data berupa frekuensi kata. Studi McCallum & Nigam banyak dijadikan rujukan pada konteks Naive Bayes untuk kategorisasi teks.

2.6 Multi-Layer Perceptron

MLP merupakan jaringan saraf feedforward yang dapat mempelajari pola non-linear. Dalam scikit-learn, MLP dapat digunakan untuk klasifikasi teks, tetapi sering membutuhkan pengaturan parameter dan data yang memadai agar stabil.

2.7 Penanganan Ketidakseimbangan Kelas: SMOTE

Pada data yang tidak seimbang, model cenderung bias ke kelas mayoritas. SMOTE (Synthetic Minority Over-sampling Technique) menambah sampel sintetis pada kelas minoritas untuk memperbaiki proses pembelajaran.Lokasi penelitian merupakan objek penelitian dimana kegiatan penelitian dilakukan. Penentuan lokasi penelitian dimaksudkan untuk mempermudah atau memperjelas lokasi yang menjadi sasaran dalam penelitian. Adapun alasan dipilihnya lokasi penelitian di Desa Sekarwangi Kecamatan Cibadak Kabupaten Sukabumi sebagai lokasi penelitian yaitu karena di Desa Sekarwangi khususnya di kampung Cikiwul belum pernah diadakan penelitian yang serupa, mengenenai alasan sikap masyarakat Kampung Cikiwul yang masih menggunakan metode penyiraman Manual.

3. Metodologi Penelitian

3.1 Pengumpulan Data

Data ulasan dikumpulkan dari Google Play Store menggunakan pustaka google-play-scraper dengan parameter:

- appId = com.roblox.client
- Bahasa (lang) = id
- Negara (country) = id
- Pengurutan(sort)=MOST_RELEVANT
- Jumlah target (count) = 20.000 ulasan (dengan mekanisme paginasi).

Output scraping kemudian disimpan menjadi CSV berisi userName, score, at, dan content

3.2 Pra-pemrosesan Data

Tahapan pra-pemrosesan mengikuti kode yang digunakan, yaitu:

- Menghapus duplikasi berdasarkan kolom content.
- Mengisi nilai kosong pada content.
- Cleaning teks: menghapus URL, HTML tag, emoji, simbol, dan angka.
- Case folding: mengubah teks menjadi huruf kecil.
- Normalisasi kata tidak baku menggunakan kamus (mis. tidak_baku → kata_baku).
- Tokenisasi (pemisahan kata).
- Penghapusan stopwords bahasa Indonesia dari NLTK.
- Stemming menggunakan PySastrawi

3.3 Pelabelan Sentimen

Label sentimen dibentuk dari skor ulasan:

- Negatif jika skor ≤ 3
- Positif jika skor > 3

3.4 Ekstraksi Fitur

Fitur teks dibentuk dengan dua pendekatan sesuai eksperimen pada notebook:

- CountVectorizer (Bag-of-Words) untuk menghitung kemunculan kata.
- TfidfVectorizer (TF-IDF) untuk bobot kata berbasis TF-IDF.

3.5 Pembagian Data

Data dibagi menjadi data latih dan data uji menggunakan train_test_split dengan *stratify=y* agar proporsi kelas tetap seimbang pada kedua subset.

3.7 Pemodelan dan Evaluasi

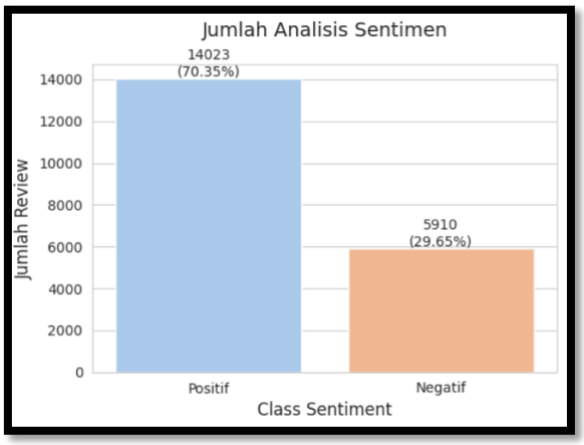
Model yang dibandingkan:

- SVM (kernel linear)
- Multinomial Naive Bayes
- MLPClassifier (Deep Learning sederhana)

Evaluasi menggunakan: akurasi, classification report (precision/recall/F1), confusion matrix, serta AUC-ROC untuk model yang menghasilkan probabilitas. Implementasi pemodelan dilakukan dengan scikit-learn.

4. Hasil Kegiatan Riset

4.1 Deskripsi data dan distribusi sentiment



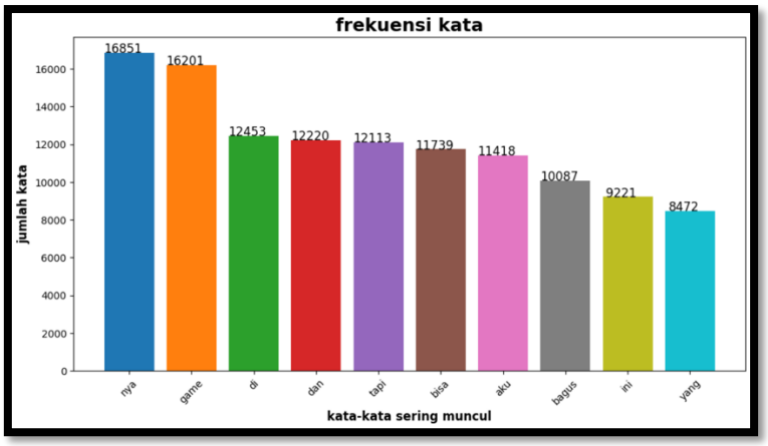
Gambar 1. Distribusi jumlah ulasan berdasarkan kelas sentimen (positif dan negatif)

Berdasarkan proses scraping dan pembersihan data, jumlah ulasan yang digunakan pada tahap analisis sentimen adalah 19.933 ulasan. Pelabelan sentimen dilakukan otomatis berdasarkan skor ulasan, yaitu negatif untuk skor ≤ 3 dan positif untuk skor > 3. Hasil pelabelan menunjukkan kelas positif berjumlah 14.023 (70,35%) dan kelas negatif berjumlah 5.910 (29,65%).

Kondisi ini menandakan adanya ketidakseimbangan kelas (class imbalance), karena ulasan positif jauh lebih dominan dibanding ulasan negatif. Ketidakseimbangan ini umumnya membuat model cenderung lebih mudah memprediksi kelas mayoritas (positif), sementara kelas minoritas (negatif) menjadi lebih menantang untuk dikenali secara konsisten.

4.2 Analisis kata dominan (word cloud dan frekuensi kata)

Hasil visualisasi word cloud pada data menunjukkan kata-kata yang sering muncul seperti “game”, “gamenya”, “bagus”, “seru”, “main”, “roblox”, serta kata yang mengarah pada keluhan seperti “bug”, “login”, “ngelag”, “tolong”, dan “perbaiki”.



Gambar 2. Grafik frekuensi kata (10 kata teratas)

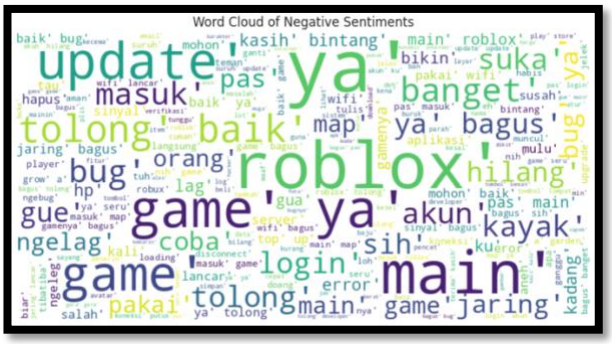
Pada grafik frekuensi kata (10 kata teratas), kata yang paling sering muncul adalah: “nya” (16.851), “game” (16.201), “di” (12.453), “dan” (12.220), “tapi” (12.113), “bisa” (11.739), “aku” (11.418), “bagus” (10.087), “ini” (9.221), dan “yang” (8.472).

Temuan ini menunjukkan bahwa selain kata-kata tematik (misalnya “game”, “bug”, “login”), masih terdapat kata umum/partikel yang dominan (“nya”, “di”, “dan”, “yang”). Hal ini wajar pada data ulasan berbahasa Indonesia, namun dapat mengurangi ketajaman analisis topik jika tidak ditangani dengan stopwords tambahan (custom stopwords).

4.3 Word cloud per kelas sentiment

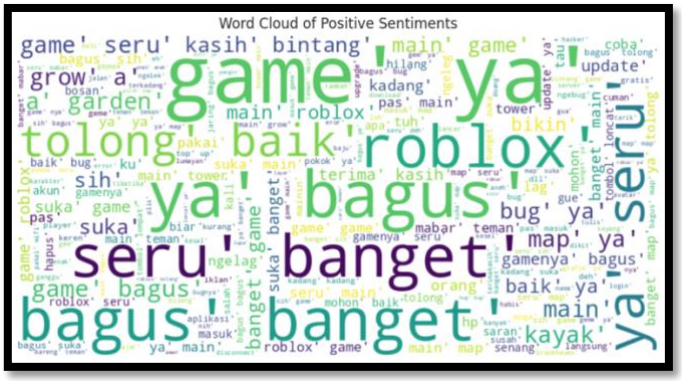
Word cloud per sentimen memperlihatkan perbedaan fokus isi ulasan:

a. Sentimen negatif cenderung didominasi kata seperti “login”, “bug”, “ngelag”, “error”, “server”, “update”, “hilang”, “sinyal/jaringan”, dan “tolong”. Ini mengindikasikan keluhan utama pengguna berkaitan dengan stabilitas aplikasi, akses akun, serta konektivitas.



Gambar 3. Word cloud sentimen negatif pada ulasan Roblox

b. Sentimen positif didominasi kata “bagus”, “seru”, “banget”, “suka”, “main”, dan kata terkait pengalaman bermain. Ini menunjukkan bahwa pengguna yang memberi ulasan positif lebih menekankan aspek keseruan dan kualitas permainan.

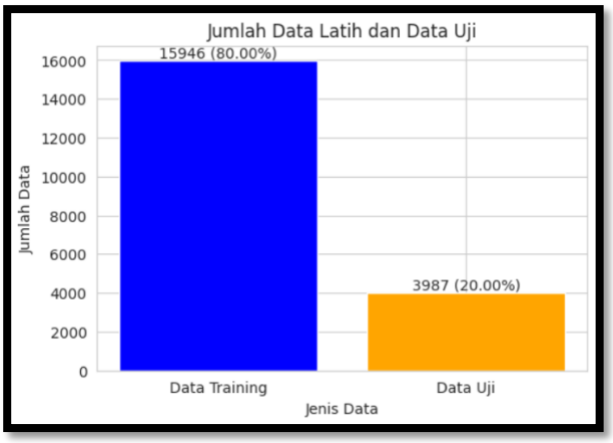


Gambar 4. Word cloud sentimen positif pada ulasan Roblox

Secara umum, hasil ini mendukung bahwa ulasan negatif lebih banyak berisi masalah teknis, sedangkan ulasan positif lebih banyak berisi apresiasi terhadap pengalaman bermain.

4.4 Pembagian data latih dan data uji

Data dibagi menjadi 80% data latih dan 20% data uji. Hasil pembagian menunjukkan 15.946 data latih (80%) dan 3.987 data uji (20%). Pembagian ini bertujuan memastikan model dievaluasi pada data yang belum pernah dilihat saat pelatihan sehingga performa yang diperoleh lebih merefleksikan kemampuan generalisasi.



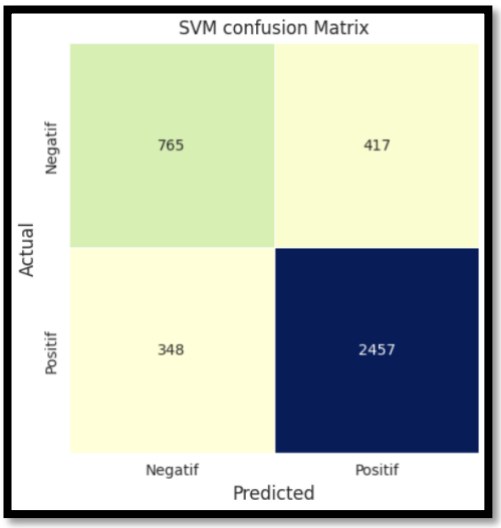
Gambar 5. Pembagian data latih dan data uji pada dataset ulasan Roblox

4.5 Evaluasi model berdasarkan confusion matrix

Berdasarkan confusion matrix pada data uji (3.987 ulasan), diperoleh hasil berikut:

a. **SVM**
TN = 765, FP = 417, FN = 348, TP = 2.457
Akurasi = 80,81%

Model SVM menunjukkan kemampuan yang kuat dalam mengenali ulasan positif (TP tinggi), namun masih terdapat jumlah FP yang cukup besar (417), yaitu ulasan negatif yang diprediksi sebagai positif. Ini konsisten dengan kondisi data yang didominasi sentimen positif, sehingga model cenderung "bermain aman" memilih kelas mayoritas.

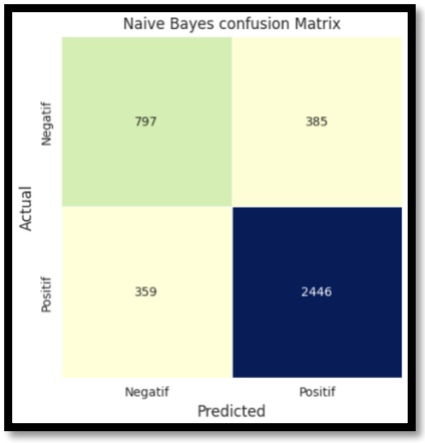


Gambar 6. Confusion matrix model SVM pada data uji

b. Naive Bayes

TN = 797, FP = 385, FN = 359, TP = 2.446
Akurasi = 81,34%

Naive Bayes memiliki FP lebih rendah dibanding SVM (385 vs 417), yang berarti model ini sedikit lebih baik dalam menahan kecenderungan memprediksi positif secara berlebihan. Namun, FN sedikit lebih tinggi daripada SVM, menunjukkan masih ada ulasan positif yang tertukar menjadi negatif.

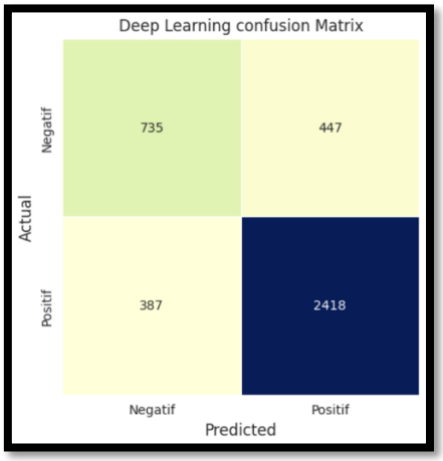


Gambar 7. Confusion matrix model Naïve Bayes pada data uji

c. Deep Learning (MLP)

TN = 735, FP = 447, FN = 387, TP = 2.418
Akurasi = 79,08%

MLP menghasilkan FP dan FN yang lebih tinggi dibanding dua model lain, sehingga performanya paling rendah pada evaluasi ini. Hal ini dapat terjadi karena MLP pada representasi fitur sparse (teks vektorisasi) cenderung lebih sensitif terhadap parameter pelatihan dan tidak selalu unggul tanpa tuning yang lebih mendalam.



Gambar 8. Confusion matrix model Deep Learning (MLP) pada data uji

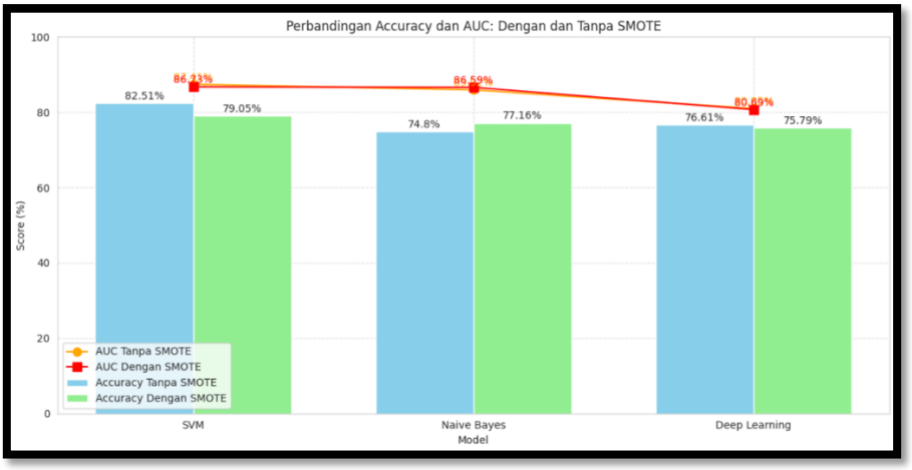
Jika dilihat dari sisi pengenalan kelas negatif (yang lebih sulit karena minoritas), Naive Bayes relatif lebih baik dibanding SVM dan MLP karena memiliki FP lebih kecil dan TN lebih besar.

4.6 Perbandingan kinerja berbasis AUC-ROC dan pengaruh SMOTE

Hasil ROC Curve menunjukkan nilai AUC masing-masing model sebagai berikut: SVM (0,87), Naive Bayes (0,86), dan Deep Learning/MLP (0,80). Nilai AUC yang lebih tinggi menandakan kemampuan model membedakan dua kelas (positif vs negatif) secara lebih baik pada berbagai ambang keputusan. Pada grafik perbandingan akurasi dan AUC, SVM konsisten menjadi model dengan AUC tertinggi, menunjukkan bahwa model ini memiliki daya pisah kelas yang lebih kuat dibanding model lain.

Eksperimen SMOTE dilakukan untuk menangani ketidakseimbangan kelas pada data latih. Hasilnya menunjukkan bahwa SMOTE tidak selalu meningkatkan performa semua model:

- Pada SVM dan MLP, akurasi cenderung menurun setelah SMOTE. Salah satu penyebab yang umum adalah sampel sintetis dari SMOTE pada ruang fitur teks (TF-IDF yang sangat sparse) dapat membuat batas keputusan bergeser dan menambah "noise" sehingga tidak selalu membantu model margin seperti SVM.
- Pada Naive Bayes, performa justru meningkat setelah SMOTE. Hal ini masuk akal karena Naive Bayes berbasis probabilitas kata; menambah representasi kelas minoritas dapat membantu estimasi distribusi kata untuk kelas negatif sehingga prediksi lebih seimbang.



Gambar 9. Perbandingan akurasi dan AUC tiap model (SVM, Naive Bayes, dan MLP) pada kondisi tanpa SMOTE dan dengan SMOTE.

4.7 Pembahasan utama temuan

Secara keseluruhan, hasil menunjukkan bahwa SVM dan Naive Bayes lebih stabil dibanding MLP pada klasifikasi sentimen berbasis fitur teks (TF-IDF/BoW). SVM unggul pada kemampuan pemisahan kelas secara umum (terlihat dari AUC tertinggi), sedangkan Naive Bayes cenderung lebih baik dalam menahan bias terhadap kelas mayoritas pada beberapa skenario (terlihat dari FP yang lebih rendah pada confusion matrix). MLP memiliki performa lebih rendah, yang mengindikasikan bahwa pendekatan deep learning sederhana belum tentu unggul untuk data teks sparse tanpa optimasi arsitektur dan hyperparameter yang lebih lanjut. Selain itu, perlu diperhatikan bahwa pelabelan sentimen berbasis rating memiliki potensi noise, terutama pada ulasan dengan skor 3 (yang bisa bersifat netral/ambigu). Kondisi ini dapat menyebabkan sebagian ulasan sulit dipisahkan secara tegas menjadi positif atau negatif, sehingga membatasi performa maksimum model.

KESIMPULAN

a. Penelitian ini menganalisis 19.933 ulasan aplikasi Roblox (hasil scraping 20.000 data) dengan pelabelan otomatis berbasis skor, menghasilkan distribusi sentimen 14.023 positif (70,35%) dan 5.910 negatif (29,65). Data diproses melalui tahap preprocessing (cleaning, normalisasi, stopwords removal, stemming Sastrawi) dan diekstraksi menggunakan TF-IDF.
b. Evaluasi model menunjukkan SVM tanpa SMOTE memberikan hasil terbaik dengan akurasi 82,51% dan AUC 0,87. Naive Bayes memiliki performa yang kompetitif dengan akurasi sekitar 81,34% dan AUC 0,86, sedangkan model Deep Learning (MLP) menghasilkan performa lebih rendah dengan akurasi sekitar 79,08% dan AUC 0,80.
c. Penerapan SMOTE tidak selalu meningkatkan performa. SMOTE cenderung meningkatkan Naive Bayes (akurasi naik dari 74,80% menjadi 77,16% dan AUC dari 0,86 menjadi 0,87), namun pada SVM dan MLP justru menurunkan akurasi; sehingga SVM tetap menjadi model paling konsisten dan direkomendasikan untuk dataset ini.

DAFTAR PUSTAKA

[1] R. S. Wibowo, M. R. W. R. Rakan, J. B. N. Miko, and M. Arifin, "Analisis Sentimen Menggunakan Support Vector Machine dan Naive Bayes Pengguna Game Roblox," JUKOMIKA (Jurnal Ilmu Komputer dan Informatika), vol. 8, no. 2, pp. 106–112, 2025.
[2] N. K. F. P. Dewi, I. G. I. Sudipa, I. W. Sunarya, N. W. J. K. Dewi, and A. S. Kusuma, "Sentiment Analysis of Roblox Game Reviews Using Support Vector Machine Method," Sinkron: jurnal dan penelitian teknik informatika, vol. 9, no. 4, pp. 1863–1876, 2025.
[3] F. Ansyah and R. R. Suryono, "Sentiment Classification of Indonesian-Language Roblox Reviews Using IndoBERT with SMOTE Optimization," Journal of Applied Informatics and Computing, vol. 9, no. 4, pp. 1868–1877, 2025.
[4] S. Sasmita, R. N. J. S. Intam, D. Fatmarani Surianto, et al., "Analisis Sentimen Terhadap Kontroversi Putusan MK Mengenai Usia Capres-Cawapres Menggunakan Multi-Layer Perceptron Dengan Teknik SMOTE," Faktor Exacta, vol. 17, no. 2, pp. 188–198, 2024.
[5] Analisis Sentimen Berbasis Aspek terhadap Data Ulasan Pengguna Pada Game Roblox Dengan Metode Support Vector Machine
[6] A. F. Alkindi and N. Nasution, "Analisis Sentimen Ulasan Pengguna Pada Game Roblox Dengan Metode Support Vector Machine Dan Naive Bayes," J-Com (Journal of Computer), vol. 4, no. 2, pp. 164–177, 2024.
[7] E. F. Baharsyah, Armanto, T. H. B. Aviani, and C. Wulandari, "Analisis Sentimen Pengguna Terhadap Aplikasi Belajar Online Ruang Guru Pada Ulasan Google Play Store Menggunakan Algoritma Naïve Bayes dan Support Vector Machine," Innovative: Journal Of Social Science Research, vol. 4, no. 3, pp. 2965–2979, 2024.
[8] T. S. Gumilar, R. Astuti, and Y. A. Wijaya, "Analisis Sentimen Ulasan Aplikasi Lita Di Play Store Menggunakan Algoritma Naive Bayes," JATI (Jurnal Mahasiswa Teknik Informatika), vol. 8, no. 1, pp. 543–550, 2024.
[9] Ridwan, E. H. Hermaliani, M. Ernawati, et al., "Penerapan: Penerapan Metode SMOTE Untuk Mengatasi Imbalanced Data Pada Klasifikasi Ujaran Kebencian," Computer Science (Co-Science), vol. 4, no. 1, pp. 80–88, 2024.
[10] M. P. Pulungan, A. Purnomo, and A. Kurniasih, "Penerapan SMOTE untuk Mengatasi Imbalance Class dalam Klasifikasi Kepribadian MBTI Menggunakan Naive Bayes Classifier," Jurnal Teknologi Informasi dan Ilmu Komputer, vol. 11, no. 5, pp. 1033–1042, 2024.
[11] A. Arasy, S. Agustian, L. Handayani, and I. Iskandar, "Klasifikasi Sentimen Menggunakan Metode Multilayer Perceptron dengan Fitur TF-IDF: Sentiment Classification Using Multilayer Perceptron Algorithm with TF-IDF Features," MALCOM: Indonesian Journal of Machine Learning and Computer Science, vol. 5, no. 3, pp. 908–919, 2025.